

## Taller 4 – Machine Learning



Pontificia Universidad  
**JAVERIANA**  
Colombia

Pontificia Universidad Javeriana  
Tecnologías Emergentes

Integrantes:  
Laura Ovalle  
Sophia Aristizábal  
José Manuel Rodríguez  
Luis Vera  
Juan David González

Bogotá D.C  
8 de abril 2025

## Introducción

El presente trabajo tiene como objetivo la construcción y evaluación de un modelo de aprendizaje automático utilizando la herramienta Teachable Machine de Google. El propósito principal del modelo es clasificar imágenes en tres categorías distintas: esculturas incas, esculturas chinas (soldados de terracota) y esculturas griegas. Así mismo, a través del entrenamiento con un conjunto limitado de imágenes representativas (10 por cada categoría), se busca que el modelo logre identificar patrones visuales característicos de cada tipo de escultura. De este modo se tratará de lograr que el modelo pueda reconocer correctamente nuevas imágenes no vistas anteriormente. Este ejercicio permite explorar de forma práctica y básica los modelos de clasificación y obtener una noción inicial de cómo entrenar adecuadamente este tipo de algoritmos.

## Procedimiento

### Paso 1: Ingreso a Teachable Machine

Para realizar el proceso en primer lugar, se accedió a la plataforma *Teachable Machine* en donde se seleccionó un nuevo proyecto de imagen. Teachable Machine es una herramienta gratuita de Google que permite crear modelos de aprendizaje automático sin necesidad de programar. En este caso, al seleccionar “Proyecto de Imagen”, se realiza la preparación del modelo de Machine Learning a través de imágenes.

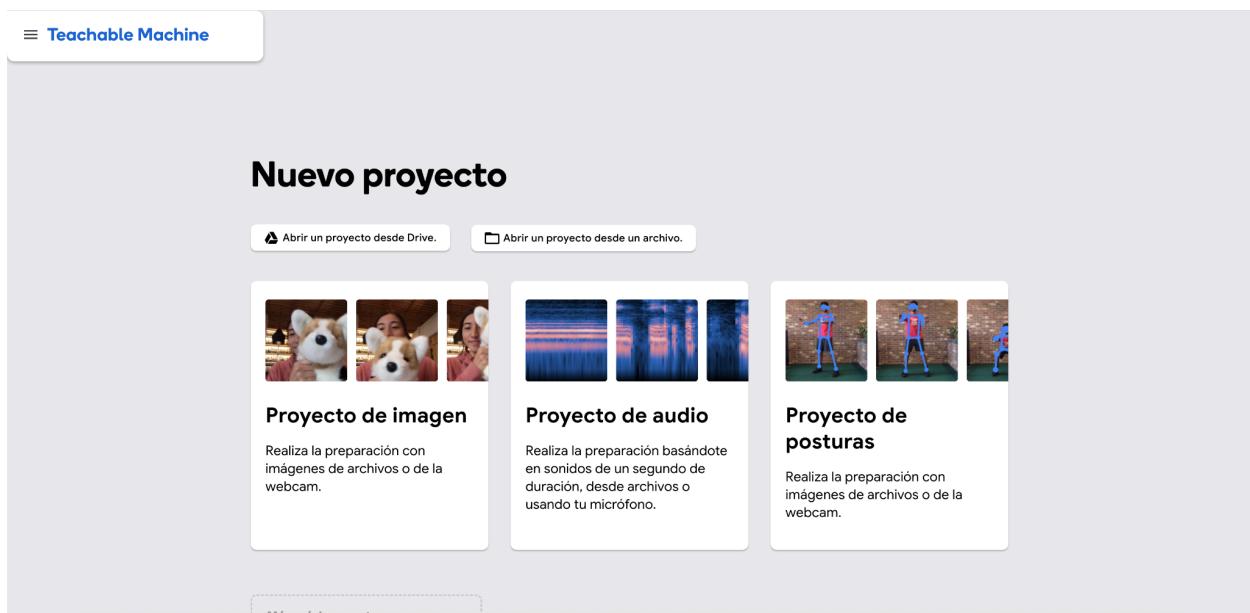


Imagen 1. Inicialización del proyecto

## Paso 2: Creación de las clases de clasificación

Posteriormente, se crearon tres clases de imágenes, cada una correspondiente a una categoría: Esculturas incas, Esculturas chinas (soldados de terracota) y Esculturas griegas.

A cada clase se le asignaron 10 imágenes para entrenamiento, las cuales fueron previamente seleccionadas para representar de forma clara las características distintivas de cada tipo de escultura. Al usar solo 10 imágenes por clase, se puede realizar un análisis más sencillo y directo de los resultados, permitiendo observar con claridad los errores de clasificación, las confusiones entre clases y el impacto visual de las diferencias entre categorías. Además, al tener un número mayor de imágenes con mayor variedad de escultura de cada tipo puede prestarse para confundir al modelo, pues aumenta la probabilidad de encontrar ciertos símiles entre las clases. Este paso se puede ver representado en la imágenes 2, 3 y 4.

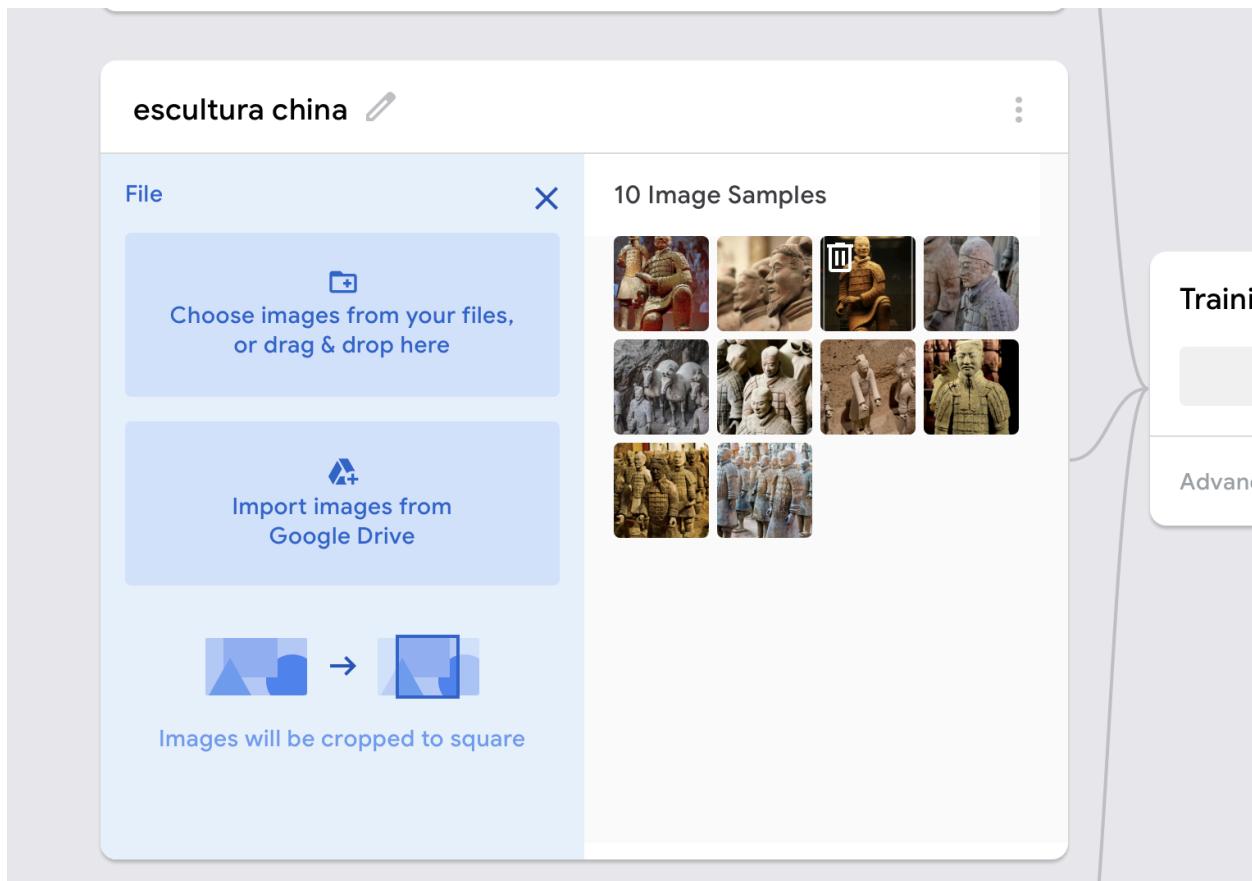
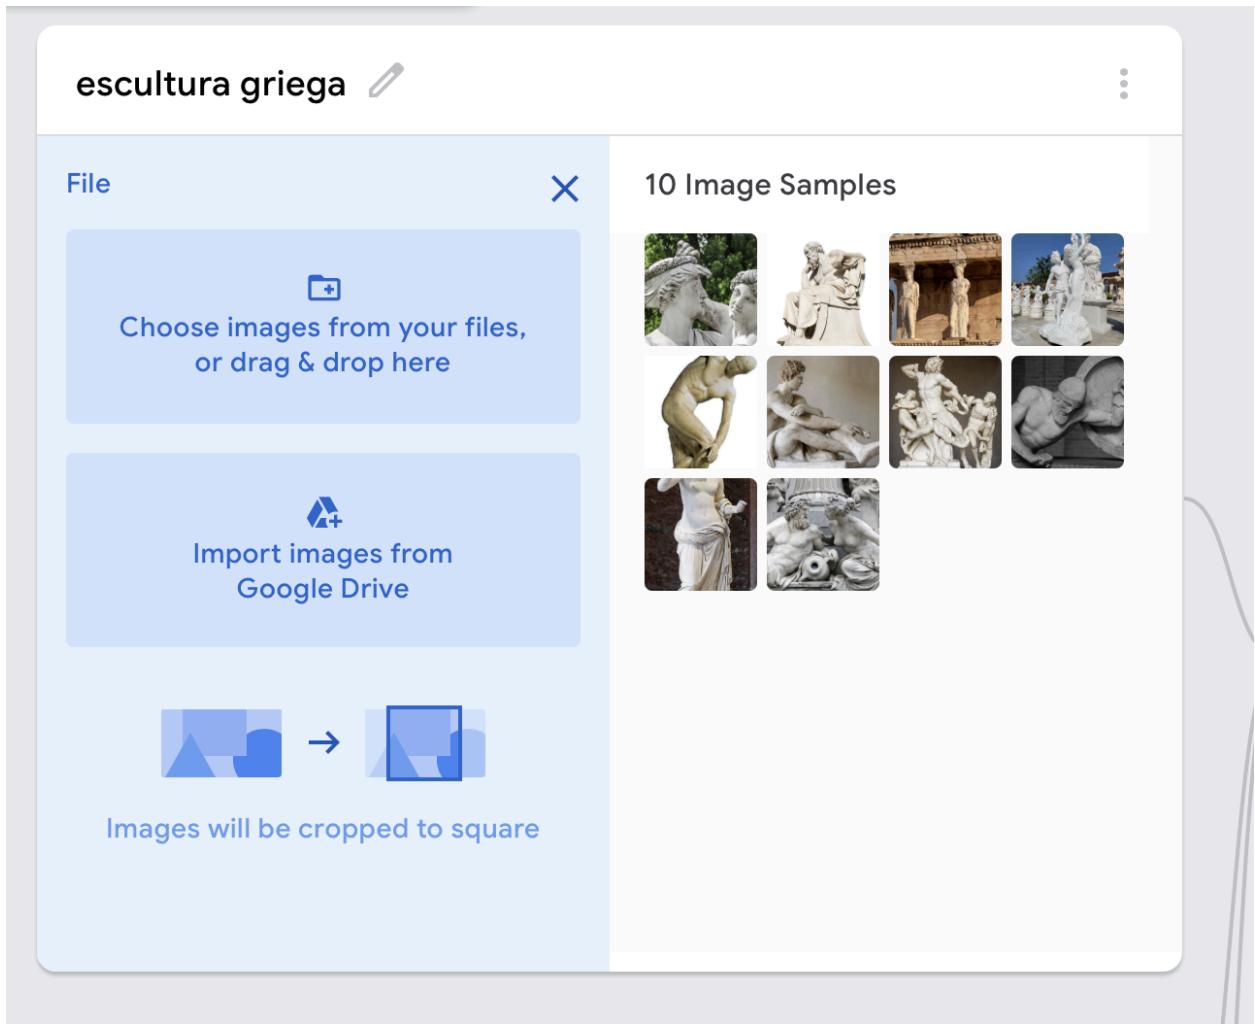


Imagen 2. Imágenes de entrenamiento esculturas Chinas



*Imagen 3. Imágenes de entrenamiento esculturas Griegas*

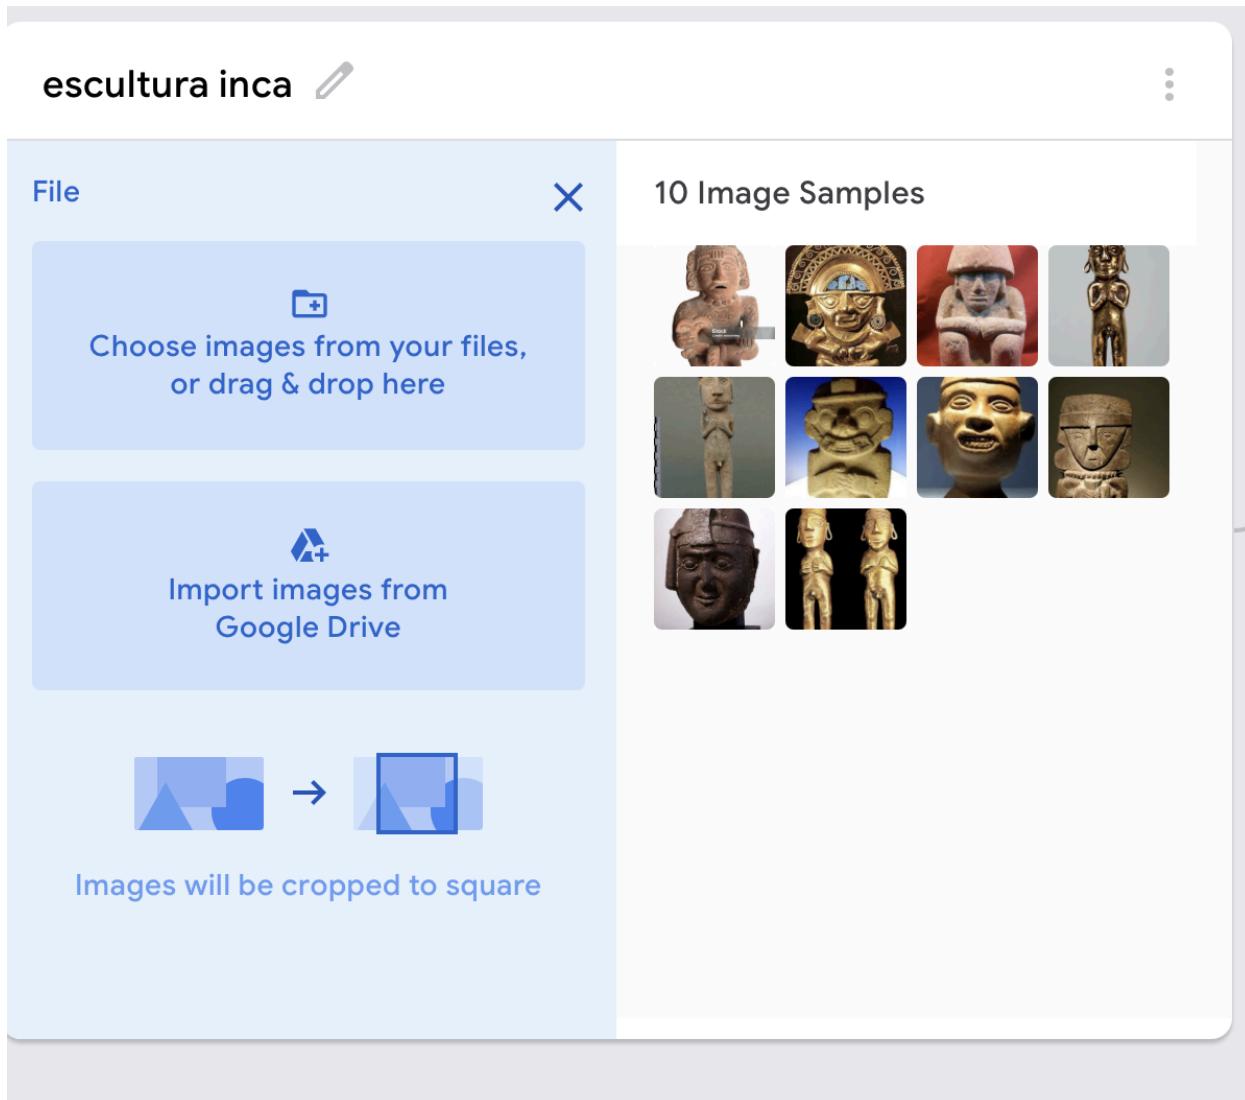
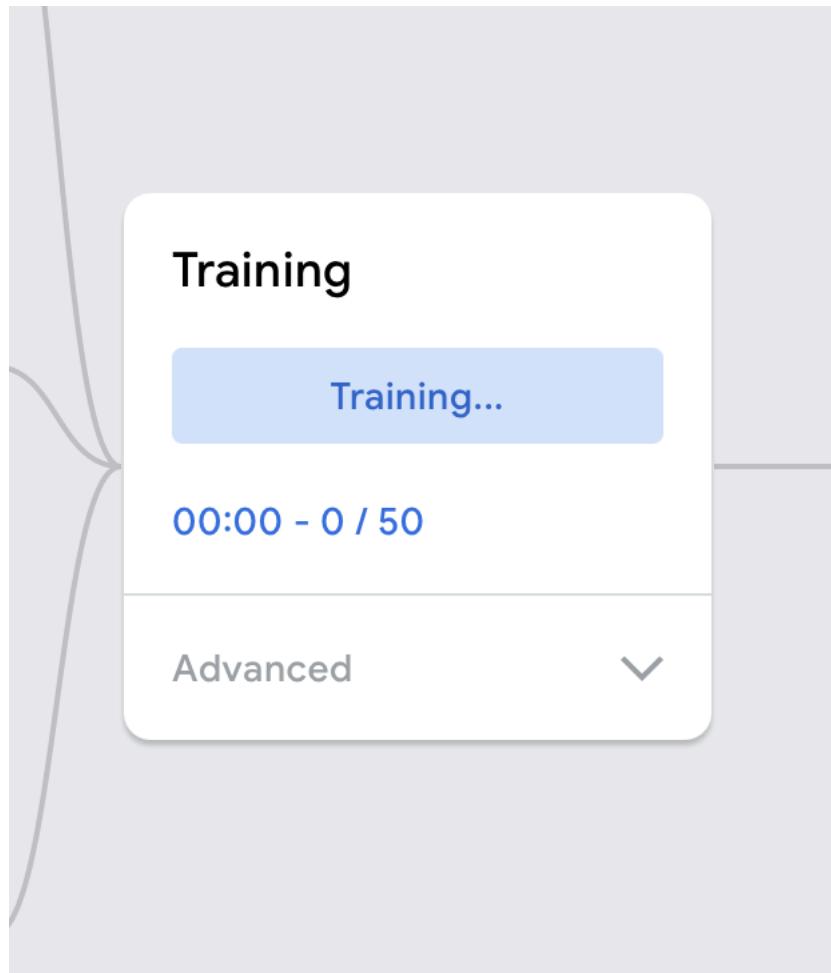


Imagen 4. Imágenes de entrenamiento esculturas Incas

### Paso 3: Entrenamiento del modelo

Una vez cargadas todas las imágenes en sus respectivas clases, se hizo clic en el botón “Train Model” para iniciar el proceso de entrenamiento. Durante este proceso, Teachable Machine utiliza técnicas de Machine Learning para aprender patrones visuales únicos de cada categoría.



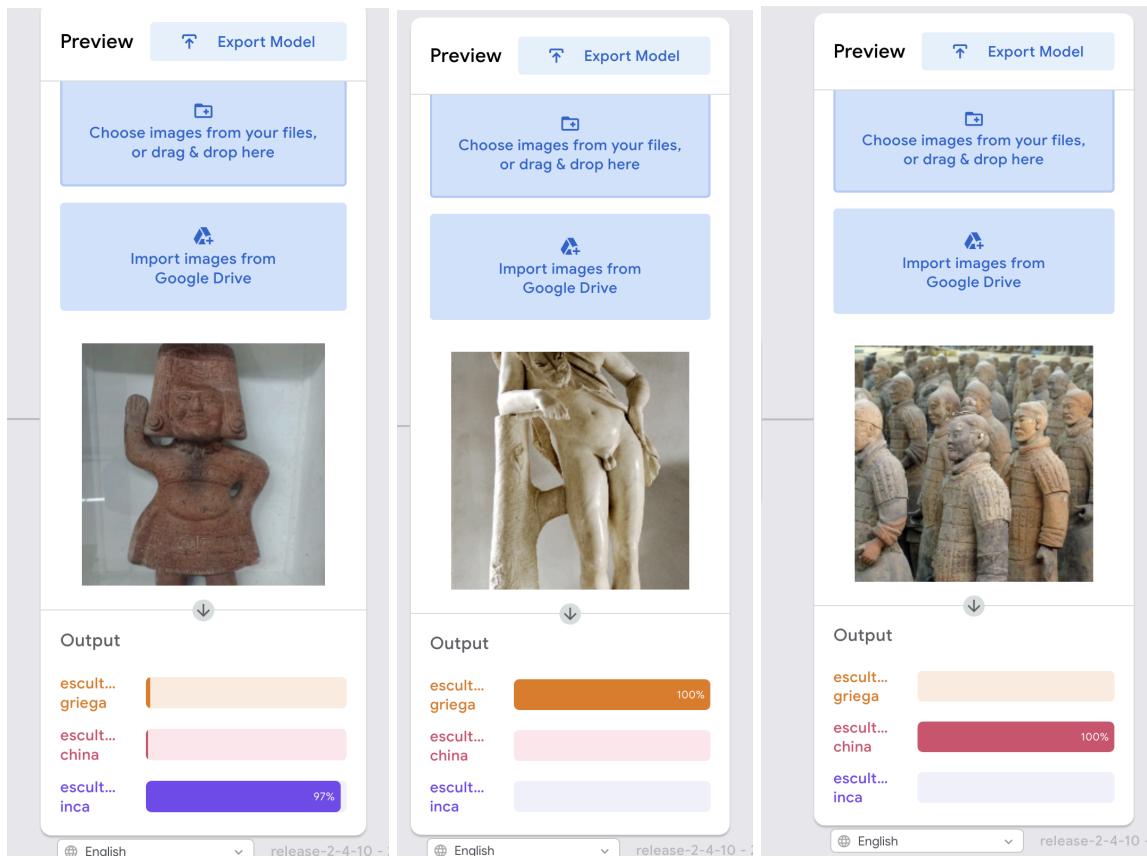
*Imagen 5. Proceso de entrenamiento del modelo*

El proceso de entrenamiento del modelo puede tardar más o menos, dependiendo de la cantidad de clases que tiene y la cantidad de imágenes de entrenamiento que se desean agregar.

#### **Paso 4: Fase de pruebas**

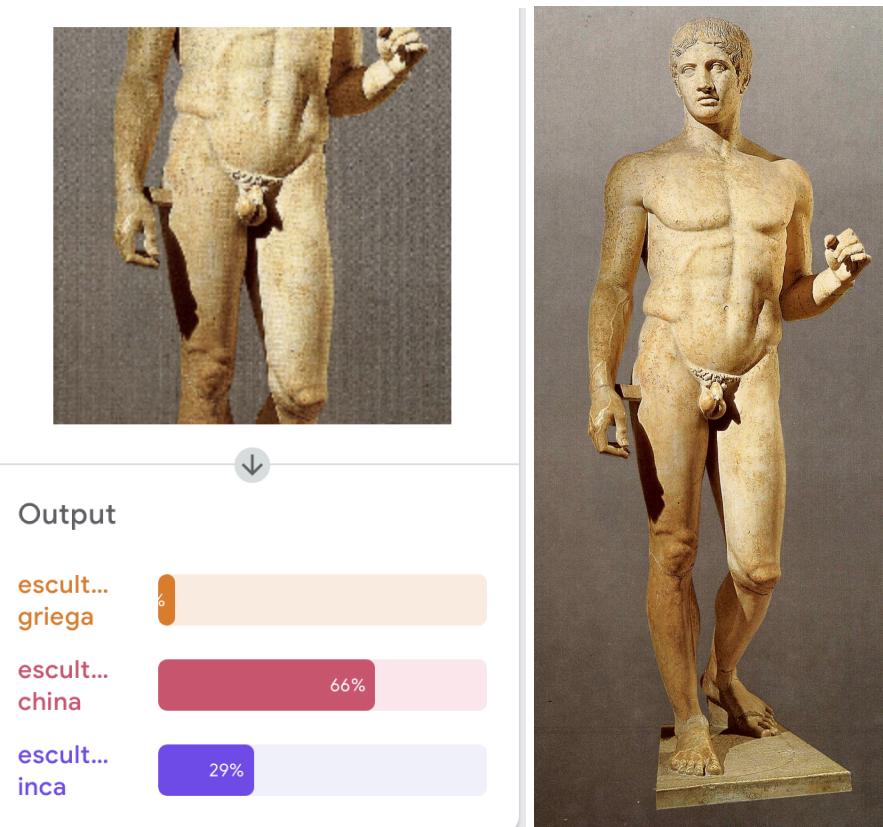
Finalizado el entrenamiento, se procedió a evaluar el modelo utilizando imágenes nuevas, distintas a las del conjunto de entrenamiento. Estas imágenes de prueba se cargaron directamente desde el equipo.

El modelo devolvió para cada imagen una predicción con porcentajes, indicando la probabilidad de que la imagen pertenezca a cada una de las tres clases. Se registraron los resultados para verificar la precisión del modelo, como se presenta en las imágenes 6, 7 y 8.



Imágenes 6, 7 y 8. Proceso de pruebas.

Es menester anotar que durante esta fase, se detectó un caso particular con una imagen correspondiente a una escultura griega (imagen 9 y 10), la cual el modelo no lograba clasificar correctamente, a pesar de haber sido entrenado con ejemplos representativos de dicha categoría. Ante esta situación, se optó por incluir esta imagen problemática dentro del conjunto de entrenamiento. Posteriormente, se entrenó nuevamente el modelo y se realizó una nueva fase de evaluación con un set diferente de imágenes. Esta estrategia permitió mejorar la precisión del modelo y reducir el margen de error, evidenciando cómo el ajuste del dataset puede impactar directamente en el rendimiento del modelo.



*Imágenes 9 y 10. Proceso de pruebas.*

## Conclusiones

Durante la fase de prueba, el modelo mostró una alta precisión en la mayoría de las clasificaciones, alcanzando porcentajes superiores al 95%. Esto demuestra que incluso con una cantidad reducida de imágenes de entrenamiento, el modelo puede obtener resultados significativos si las imágenes son representativas y bien seleccionadas.

Sin embargo, también se detectaron dificultades específicas, como la confusión en la clasificación de una escultura griega en particular. Este error pudo haberse generado debido a similitudes en el color y textura entre esta escultura griega y las esculturas chinas (soldados de terracota), lo cual podría indicar un posible sobreajuste del modelo. La problemática se solucionó eficazmente al incorporar la imagen problemática dentro del conjunto inicial de entrenamiento y realizar un reentrenamiento del modelo. Esta situación evidencia claramente la importancia de contar con un dataset amplio y diverso, lo que favorece la capacidad del modelo para generalizar y reducir errores en clasificaciones futuras.